

机器学习与人工智能快速入门 2 -- 从向量到线性回归与梯度下降

1. 需要了解的数学知识

1.1 向量转置

在数学中，向量通常写成列向量的形式，例如：

$$\mathbf{x} = \begin{bmatrix} 80 \\ 3 \\ 5 \end{bmatrix}$$

但列向量在文字段落中排版很占空间。为了书写方便，我们先用行向量写出来：

$$\mathbf{x} = [80, 3, 5]$$

然后在右上角加一个 T （代表"转置"，transpose），表示把这个行向量"竖起来"变成列向量：

$$\mathbf{x} = [80, 3, 5]^T \quad \text{等价于} \quad \mathbf{x} = \begin{bmatrix} 80 \\ 3 \\ 5 \end{bmatrix}$$

这就叫做**向量转置**，以后会经常出现。

1.2 特征向量

中学数学在学函数的时候，我们把那个影响结果的变量叫做"自变量"，用 x 表示，比如 $y=2x+1$ ，那么 x 就是自变量， y 就是因变量。在机器学习中，我们同样使用 x ，但给它换了一个名字——**特征（feature）**。一个特征就是数据的一个属性，比如房价预测中的"面积"就是一个特征。当有多个特征时，把它们组合成一个向量，就称为**特征向量（feature vector）**。

举个例子：要描述一套房子，我们用（面积，卧室数量，房龄）这三个数字，写成 $\mathbf{x} = [80, 3, 5]^T$ ，这就是一个三维的特征向量。你可以把特征向量简单理解成"把多个自变量打包在一起"。后续内容中会交替使用这几个词，意思是一样的。

1.3 向量加法

两个维度相同的向量可以相加。向量加法的规则是对应位置元素分别相加。设 $\mathbf{a} = [a_1, a_2, \dots, a_n]^T$ ， $\mathbf{b} = [b_1, b_2, \dots, b_n]^T$ ，则：

$$\mathbf{a} + \mathbf{b} = [\mathbf{a}_1 + \mathbf{b}_1 \ \mathbf{a}_2 + \mathbf{b}_2 \ \dots \ \mathbf{a}_n + \mathbf{b}_n]$$

示例：

$$\mathbf{a} = [1 \ 3 \ 5], \quad \mathbf{b} = [2 \ 4 \ 6], \quad \mathbf{a} + \mathbf{b} = [1 + 2 \ 3 + 4 \ 5 + 6] = [3 \ 7 \ 11]$$

1.4 向量点积（内积）

向量点积是两个相同维度向量之间最核心的运算之一。点积的结果是一个标量（单一数值）。

给定向量 $\mathbf{a}$ 和 $\mathbf{b}$ ，它们的点积定义为：

$$\mathbf{a} \cdot \mathbf{b} = \sum_{i=1}^n a_i \times b_i$$

即对应位置元素相乘，再将所有乘积求和。

示例：

$$\begin{aligned} \mathbf{a} &= [1 \ 2 \ 3], \quad \mathbf{b} = [4 \ 5 \ 6] \\ \mathbf{a} \cdot \mathbf{b} &= 1 \times 4 + 2 \times 5 + 3 \times 6 = 4 + 10 + 18 = 32 \end{aligned}$$

1.5 偏导数

我们从导数说起。我们知道，导数(derivative)是这个样子定义的：对于一个一元函数 $f(x)$ ，

导数 $\frac{df}{dx}$ 表示函数在 x 处的变化率。

这里是在说 x 的变化量对 $f(x)$ 的变化量“影响”是什么样子的

但是如果“影响” $f(x)$ 的变化量不止有 x 一个呢？

那么就需要偏导数了：

偏导数(partial derivative)是导数的自然推广。当一个函数有多个自变量时 $f(x_1, x_2, \dots, x_n)$ ，

偏导数 $\frac{\partial f}{\partial x_i}$ 表示在其他所有自变量不变的情况下， f 关于 x_i 的变化率，比如可以这么想：当我们想要算出自变量 $x_i \in \{x_1, x_2, \dots, x_n\}$ 的变化量是如何影响 f 的变化量时，我们把除了 x_i 以外的其他自变量“锁住”不看，只看 x_i ，然后进行计算。

所以偏导数可以理解成，在 $(x_1, x_2, \dots, x_n)$ 这么多个 x 里面每个单独的 x 的变化量是如何影响 f 变化量的。

注意，这里我们不再使用字母 d ，而是符号 ∂ ，中文读作“偏”，英文则是“partial”。计算偏导数时，把其他变量当作常数对待即可

$$\text{示例1: } f(x, y) = x^2 + 3xy + y^2$$

$$\frac{\partial f}{\partial x} = 2x + 3y + 0 = 2x + 3y \quad (\text{对 } x \text{ 求偏导时, } y \text{ 看作常数})$$

$$\frac{\partial f}{\partial y} = 0 + 3x + 2y = 3x + 2y \quad (\text{对 } y \text{ 求偏导时, } x \text{ 看作常数})$$

$$\text{示例2: } f(x, y) = x^2 y^3$$

$$\frac{\partial f}{\partial x} = 2x \cdot y^3 = 2xy^3$$
$$\frac{\partial f}{\partial y} = x^2 \cdot 3y^2 = 3x^2y^2$$

偏导数在后面优化多变量模型时会频繁用到，请务必掌握

2、入坑机器学习：单变量线性回归

2.1 问题定义


我们学过一次函数，它是这个样子：

$$y = ax + b$$

那么在图上它就是一条线。

它代表了因变量 y 和自变量 x 的一种关系。

线性回归是最简单的机器学习模型，本质就是用这样的一条线去预测 x 和 y 的关系。



观察图像上这些点的 x 和 y ，它们大致上可以被概括成中间这条线，这条线就代表我们认为 x 和 y 的大致关系。

线性回归的目标是：给定一组输入特征 x 和对应的真实输出 y ，学习到一个线性函数 $f(x)$ ，使得 $f(x)$ 能够尽可能地逼近 y 。

上面可能有点抽象，那么举个例子，假如你学习的时间越长，得到的分数就越高

不学习，得分 50 分
学习 1 小时，得分 52 分
学习 2 小时，得分 59 分

那设你的成绩是 y ，我们想要得到你学习 x 小时大概能得到多少分，那么设我们预测出来的得分是 $f(x)$

这里我们是不是可以用一条直线来预测你考了多少分：

$$f(x) = 3x + 50$$

这里我们带进去算发现 $f(x)$ 和 y 不是完全一样——毕竟 $f(x)$ 是我们预测出来的，与真实的 y 不一定是完美贴合的，但是至少我们可以得到一个大概。

在最简单的情况下，我们只有一个影响结果的特征 x ，称为**单变量线性回归**。其模型假设为：

$$f(x) = wx + b$$

其中：

- w 叫做**权重 (weight)**，控制直线的斜率
- b 叫做**偏置 (bias)**，控制直线的截距

我们的目标是从训练数据中找出最优的 w 和 b ，使得模型预测值 $f(x)$ 尽可能接近真实值 y 。

2.3 多变量线性回归

实际问题中，一个结果往往由多个因素共同影响。预测房价时，除了面积，还可能有卧室数量、房龄、地段评分等多个因素，在这种结果被多个自变量影响的情况下，我们只有一个 x 肯定是不够的。这时需要引入**多变量线性回归**。

假设有 n 个自变量 $x_1, x_2, \dots, x_n$ ，多变量线性回归的模型为：

$$f(x_1, x_2, \dots, x_n) = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

在这里，我们有很多个 w 和 x ，那么就可以把 w 和 x 用向量来简洁表示，那么这里权重和自变量就不仅仅是。令：

则模型可以写成：

$$f(x) = w \cdot x + b$$

这里的 $w \cdot x$ 就是向量点积：对应位置相乘再求和。这个写法不仅简洁，而且运算效率更高。

示例：假设预测房价使用三个特征：面积 x_1 、卧室数量 x_2 、房龄 x_3 。如果 $w_1 = 3, w_2 = 10, w_3 = -2, b = 20$ ，那么对于一套面积 80 平方米、3 个卧室、房龄 5 年的房子：

$$f = 3 \times 80 + 10 \times 3 + (-2) \times 5 + 20 = 240 + 30 - 10 + 20 = 280$$

预测价格为 280 万元。

3、优化算法：梯度下降 (gradient descent)

3.1 损失函数：衡量模型的好坏

在上面，我们得到 $f(x)=wx+b$ 后，如何判断得到的 w 和 b 的好坏？我们需要一个量化的指标——损失函数 (loss function)，此处我们使用字母 L ，其他地方可能用不同的字母。损失函数可以理解为，我们预测出来的结果，和真实结果差了多少。

最常用的损失函数是**均方误差（Mean Squared Error, MSE）**。对于 m 个样本 $(x^{(i)}, y^{(i)})$ ，定义：

$$L(w, b) = \frac{1}{2m} \sum_{i=1}^m (f(x^{(i)}) - y^{(i)})^2$$

其中 $f(x^{(i)}) = wx^{(i)} + b$ 是第 i 个样本的预测值。

这个公式的含义：

- $(f(x^{(i)}) - y^{(i)})$ 是预测值与真实值的误差
- 平方运算消除了正负号，同时放大了较大误差
- 对所有样本取平均，得到一个整体指标
- 乘以 $\frac{1}{2}$ 是为了后续求导时公式更整洁

L 的值越小，说明模型的预测越准确。我们的目标就是找到 (w, b) 使 L 最小化。


除了 MSE，还有很多种不同的损失函数，我们以后会提到。

3.2 单变量梯度下降

现在核心问题来了：如何找到最好的 w 和 b 使得 L 可以最小？

如果我们把损失函数的图像画出来，可能是一个奇形怪状的样子，更有多维情况我们根本画不出来。但是我们可以想想简单的情况，假如只有一个变量影响 L ，那么我们就可以在一个二维平面上把函数图像画出来了。

假设偏置 $b = 0$ ，模型只有 w 这一个参数。此时损失函数 $L(w)$ 是一个关于 w 的二次函数，形状像一个碗。碗底对应损失最小的 w ，也就是我们想找到的最优值。



假设当前 w 的取值在碗的某个位置，我们如何一步步走向碗底？

分析一下：在碗底左边，我们要让 w 增加一点，在碗底右边，我们要让 w 减小一点。

w 加上或者减掉一个什么东西，让 w 在碗底左边是变大，在碗底右边是变小

导数看起来是不是最适合这个？

$$w - \frac{dL}{dw}$$

在碗底左边，导数为负， w 减去一个负数就是变大，在碗底右边，导数为正， w 减去一个正数就是变小。

但如果只有导数，我们会发现一个问题：当位置非常陡峭的时候，导数很大，一下子减去这个导数，可能直接跳过碗底到对面去了。我们不要跳这么大。在导数之前乘上一个系数，比如 0.001，这下好多了。这个系数就叫做“学习率”（learning rate）

$$w_{new} = w - \alpha \frac{dL}{dw}$$

其中：

- α 是学习率，用于控制整体步长大小
- $\frac{dL}{dw}$ 是损失函数对 w 的导数

我们反复进行很多次，这一次算出来的 w_{new} 又变成下一步的 w ，又得到一个新的 w_{new} ，如此往复，到碗底时，导数变成 0 了， w 再怎么减也不会动了，我们不就得到最优解了吗？这个操作就叫做梯度下降（gradient descent）

3.3 多变量梯度下降

现实中的模型往往有多个参数。以单变量线性回归 $f(x) = wx + b$ 为例，我们就有 w 和 b 两个参数需要优化。损失函数 $L(w, b)$ 现在是一个关于 w 和 b 的二元函数。

在多个参数的情况下，我们无法再用单一的导数来衡量变化率，因为每个参数对 J 的影响是独立的。这时就需要用到偏导数。

对于参数 w ，我们计算梯度 $\frac{\partial L}{\partial w}$ ，它告诉我们当 b 固定时， L 随 w 的变化率。同理， $\frac{\partial L}{\partial b}$ 告

诉我们当 w 固定时， J 随 b 的变化率。

将所有偏导数组合成一个向量，称为梯度（gradient）：

$$\nabla L = \left[\frac{\partial L}{\partial w}, \frac{\partial L}{\partial b} \right]^T$$

梯度的方向就是函数上升最快的方向。因此，要下降，就往梯度的反方向走。

多变量梯度下降的更新规则：

$$w_{new} = w - \alpha \frac{\partial L}{\partial w}$$

$$b_{new} = b - \alpha \frac{\partial L}{\partial b}$$

现在计算偏导数。对于 $f(x) = wx + b$ ，损失函数为：

$$L(w, b) = \frac{1}{2m} \sum_{i=1}^m (wx^{(i)} + b - y^{(i)})^2$$

对 w 求偏导（把 b 看作常数）：

$$\frac{\partial L}{\partial w} = \frac{1}{m} \sum_{i=1}^m (wx^{(i)} + b - y^{(i)}) \cdot x^{(i)}$$

对 b 求偏导（把 w 看作常数）：

$$\frac{\partial L}{\partial b} = \frac{1}{m} \sum_{i=1}^m (wx^{(i)} + b - y^{(i)})$$

可以看到，对 w 的偏导只比单变量时多了一个 b ，结构完全一致。对 b 的偏导更简单，

因为 $\frac{\partial (wx+b)}{\partial b} = 1$ 。

那么总结一下上面说的，对于参数 θ ，梯度下降在第 i 步的公式是：

$$\theta_i = \theta_{i-1} - \eta \cdot \frac{\partial L(\theta_{i-1})}{\partial \theta}$$

以上内容就是机器学习与人工智能快速入门第二课需要了解的知识，如果你有任何疑问，欢迎与我们交流。