

A1 人工智能 机器学习与伦理

这一课先用一个可以手算的小例子解释电脑怎样从例子中改进，再认识人工智能的几种做法，最后讨论如何检查聊天回答、保护同学的资料。只需要会加减乘除。可以先读计算例子，再读聊天回答与资料使用边界，不必一次读完。

0 电脑怎样从例子中改进

电脑执行的是人安排的一步步操作，例如“读取数量，再乘以单价，最后显示总价”。这样一组可以照着执行的步骤叫程序；解决问题的具体步骤或方法叫算法。它们并不需要有人意识才能算出结果。

先做一台估价小机器：输入购买苹果的个数 x ，用“总价 = $a \times x$ ”估计要付多少钱。这里 x 是交给机器的内容，叫输入；算出的总价叫输出。这条计算规则就是一个非常简单的模型。 a 是允许调整的数字，叫参数；“模型”在这里不是实物模型，也不是有思想的人。

我们有两条已知记录：买 1 个花 3 元，买 2 个花 6 元。这些记录叫数据。一开始把 a 设成 2，模型会算出 2 元和 4 元；与已知答案相比，都少算了。把 a 改成 3 后，它算出 3 元和 6 元，与这两条记录一致。根据例子比较答案、调整参数的过程叫训练。这个例子中，人能直接找到 3；复杂任务则由训练程序反复计算应该怎样调。

训练后固定 $a = 3$ ，再问买 4 个多少钱，模型算出 12 元。这种用已有模型给新输入算答案的过程叫推理；这里的推理不等于人类有意识地思考。这个模型只适用于单价不变的情况，遇到买三送一就可能算错。学会已有记录，并不保证任何新问题都答对。

试一试：如果 a 仍是 2，买 3 个会预测多少钱？若真实总价是 9 元，预测少了多少？答案是预测 6 元、少了 3 元。你已经经历了“给输入、算预测、比答案”的过程。

1 先区分三个范围

为什么先分清这三个范围？看到聊天机器人、图片识别或固定规则程序时，我们常把它们都叫作“AI”，却容易误以为它们使用同一种方法。先分清大范围和具体方法，后面才知道每个例子究竟在学什么。

人工智能（Artificial Intelligence，简称 AI）是让计算机完成识别图片、理解文字、安排步骤等任务的研究领域和技术。它包括多种做法。例如，人可以直接写下“温度超过 30°C 就开风扇”的规则，也可以让程序根据已有例子调整模型。不是所有 AI 都要先从例子中学习。

机器学习（Machine Learning，简称 ML）是根据数据调整模型，使它能处理新输入的方法。刚才调整苹果单价就是一个极简例子。识别猫狗时，一张图片可以作为一条记录；人写上的“猫”或“狗”叫标签，也就是这条记录提供的目标答案。模型先给出自己的判断，再根据它与标签的差别调整参数。

如果计算任务更复杂，可以把许多小计算连接起来：每个小计算先把几个输入分别乘上可调数字，再相加，必要时按一条额外规则改变结果。例如“ $2 \times \text{输入一} + 3 \times \text{输入二}$ ”，算完后把负结果改成 0。这样的计算单元叫人工神经元；许多单元连起来的模型叫神经网络。它是一种数学计算安排，不是真实脑细胞。

把一组单元的结果交给下一组继续算，就形成一层接一层的结构。使用多层神经网络学习的方法叫深度学习（Deep Learning，简称 DL）；“深”主要说的是计算的层次，不代表更有意识，也不保证结果更可靠。A4 会带你亲手算这些步骤，现在只需知道这些名称对应的是数字计算。

它们的关系是：深度学习属于机器学习，机器学习属于人工智能。也就是说，所有深度学习都是机器学习，但机器学习还有别的做法，例如刚才只调整一个单价的模型。先能用例子说明这个关系，再记英文缩写。

2 用同一个任务比较

方法	如何判断一张图片是否有猫
人工编写规则	设计“耳朵、胡须、轮廓”等规则；真实图片变化多，规则可能覆盖不全。
从数据中学习	用带有“猫 / 非猫”标签的图片训练，学习输入与标签的关系，再测试新图片。

多层计算能将输入的数字变成新的数字组合，供后续判断使用，但仍需要人选择数据、任务和检查办法。更多数据不一定更好：答案标错、重复记录或与实际使用场景差别太大的数据，都可能妨碍学习。

3 聊天模型放在哪里

为什么还要单独看聊天模型？日常接触到的是一个能对话的产品，想一想的却可能是模型本身。把产品与模型分开，才能判断一句回答是模型生成的，还是搜索、文件等工具提供的。

能根据已有文字生成后续文字的模型叫语言模型。人们把其中规模较大、通常经过大量文字训练的一类叫大语言模型，英文是 Large Language Model，简称 LLM。常见的聊天模型使用上面说的神经网络：输入文字先换成数字，再经过许多步计算，决定后面接什么。

模型处理文字时，先按固定的切分规则把文字拆成小块。这样的文字小块叫词元，英文 token。一个词元可能是一个字、几个字、一个词的一部分或标点，不固定等于一个汉字。这里假设把“我喜欢苹果”切成“我 / 喜欢 / 苹果”，只是教学示意；实际模型未必这样切。

模型本次能参考的材料叫上下文，例如你的问题、部分先前对话或应用提供的文件内容。给定“我喜欢”，模型会为后面可能接的小块计算不同分数，再按选取规则接上一个小块；接上“苹果”以后，新的文字又成为下一步的输入。A5 会手算候选分数怎样参与选择。

为什么这种做法能回答问题？训练文字里不只有句子的开头，还可能有“问题后面接回答”“步骤后面接结果”的例子。通过大量计算调整参数后，模型能学到许多这样的关系；聊天模型通常还会经过进一步训练，练习遵循要求和产生更合适的回答。这不保证它理解了每一条要求，也不保证每次回答正确。

聊天应用把模型、供人输入的界面，以及可能使用的搜索或文件工具组合起来。模型生成文字与工具查到资料是两件事：没有实际查询证据时，不能因为它说“我查到了”就相信它查过。模型也可能生成并不存在的书名或资料。这种看似可信却不实的内容常被叫作幻觉。

在聊天中纠正一句话，模型下一次可能因为看到了纠正内容而改变回答，这通常不等于本次对话立刻改了模型参数。服务是否另行保存对话、用于后续训练，取决于服务规定，不能从聊天表现推断。

4 样本 特征 标签与预测

为什么需要这些词？我们要分清交给模型的内容、事先知道的答案和它算出的答案。一张猫图是一条样本；图片由许多小色点组成，每个小色点叫像素，它的亮暗和颜色可以用数字表示。这些供模型计算的数字叫特征；人标注的“猫”是标签；模型给出的“狗”是预测。预测与标签不一致，才知道它这次判断错了。

名词	在猫狗分类中的例子
样本 sample	一张图片就是一个样本。
特征 feature	输入模型的数字，例如图片的像素值。
标签 label	人给图片标注的正确类别，例如“猫”。
预测 prediction	模型根据输入给出的答案，可能与标签不同。

训练是利用数据调整参数；推理是用已训练的模型做预测。训练时见过的题做对，并不意味着遇到新题也能做对。能处理未见样本的能力叫泛化，这会在 A3 进一步讨论。

5 先认识两种常见任务

分类要预测类别，例如“猫还是狗”。回归要预测数值，例如明天的温度。A2 使用回归例子，A3 使用分类例子。它们都可以是监督学习：训练数据同时给出输入和目标答案。

本系列先讲同时提供输入和目标答案的学习。其他学习方式留待掌握这条主线后再了解，不需要现在记住更多分支名称。

动手试一试一 给任务分类

请判断：①预测某天的温度；②判断邮件是否为垃圾邮件；③使用固定规则“温度超过 30°C 就开风扇”。哪些是回归或分类任务？能否仅凭任务就判断它一定用了机器学习？

参考答案：①是回归任务，②是分类任务；它们是否使用机器学习，要看实现方法。③是明确的规则程序，不会因为读取了温度数据就自动变成机器学习。

动手试一试二 找出输入与答案

要根据水果质量和直径判断水果类别。请指出特征、标签和一个样本。若已经把“水果类别”放进输入，再预测类别，会有什么问题？

参考答案：质量和直径是特征；类别是标签；一颗水果对应一条样本。把待预测的答案直接放入输入，会泄漏答案，无法证明模型学会了在未知类别时进行判断。

6 把使用边界落到具体做法

为什么认识概念时也要考虑使用边界？模型可能在练习题上得分很高，却在真实使用中泄露资料、对某些人表现较差，或给出难以核实的结论。下面每项原则都对应一个自己可以检查的具体行为。

公平：如果用来训练的语音大多来自同一种口音，其他口音的识别效果可能更差。正确次数除以总次数得到的比例叫准确率；不能只看总准确率，还要分别检查不同人群。收集了谁的资料、答案是否标错、打算评价什么，都可能造成不公平。

透明与可解释：要说明系统使用了哪些输入、能做什么、会在哪些情况下失败。模型生成的一段“原因说明”不自动等于其真实计算过程，也不能替代证据。

隐私：练习时使用虚构数据或已获授权的公开素材。真实姓名、成绩、联系方式、人脸照片，以及能让别人使用你账号服务的秘密凭证，都不应随意上传。同学同意参加活动，也不等于同意把个人资料发给外部服务。

问责：使用者和组织需要明确谁检查数据、谁审核输出、出错后如何处理。不能把“是 AI 决定的”当作不检查结果的理由。

安全与可控：对重要决定保留人工复核与纠错渠道。练习先在小范围和可恢复的环境中进行，遇到不确定的信息先核实。

想一想 一个社团例子

社团想根据同学的照片自动评选“最受欢迎成员”。请指出至少两个问题，并改写成一个更合适的学习项目。

参考思路：照片涉及隐私；“受欢迎”没有可靠、客观的标签；模型结果可能加剧偏见。可以改成用获授权的植物图片做种类分类，只评价模型在新图片上的表现，不评价同学。

读后自查

合上资料，尝试回答：① AI、ML、DL 是什么关系？② 训练和推理有什么不同？③ 更多数据为什么不一定更好？④ 能否说出一项使用 AI 时应遵守的具体边界？能举例说明，就可以进入 A2。