

A2 数学基础 线性回归与梯度下降

用一个完整例子理解特征 损失和参数更新

这一节用“根据学习时间预测成绩”贯穿所有概念。读完后，你应能区分输入数据和模型参数，算出一次预测误差，并说清梯度下降在做什么。

阅读前先准备

需要会正负数运算、代入简单式子、平方和平均值；这些都在初中数学范围内。向量、点积、导数和梯度会从具体数字讲起。第 6 节是选学推导，可以先学会前五节的预测和参数调整，再回来阅读。

1 从数据到特征向量

为什么要把信息变成向量？模型不能直接拿“这套房子怎么样”这样模糊的描述计算。我们先选出与任务有关、能用数字表示的属性，再按固定顺序放在一起，才方便让同一套计算处理不同样本。

机器学习中的**特征**是描述一个对象的数字属性。预测一套房子的价格时，面积、卧室数和房龄都可以是特征。把同一对象的多个特征按固定顺序排成一列，得到特征向量。顺序不能随意改变。

向量就是按固定顺序排列的一组数。含 3 个数就叫 3 维；这里的“维”只是在数有几个分量，不要求想象三维空间。横着写是行向量，竖着写是列向量。把行改成列、列改成行叫转置，右上角的 T 就表示这一步。 $[80, 3, 5]^T$ 表示把这三个数竖排，T 不是乘数，也不是乘方。

后面会把多行多列数字排成一张矩形表，叫矩阵。例如 $\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ 有两行两列。向量相加就是对应位置相加： $[1, 2]^T + [3, 4]^T = [4, 6]^T$ 。向量乘一个数，就是每个分量都乘它： $2 \times [1, 2]^T = [2, 4]^T$ 。只有分量数量一致、位置含义对应时，才按这种规则相加。

$$x = [80, 3, 5]^T$$

该特征向量表示“面积 80、3 个卧室、房龄 5 年”。

2 线性回归先做一次预测

为什么先试一条直线？我们想根据已知的学习时间和成绩，给一个新学习时间估计分数。直线只有两个可调数字，既能展示“输入变成预测”的过程，也能手算它与真实成绩差多少。

先看三个虚构样本：记录的额外学习时间为 0 小时时成绩 50 分，1 小时为 52 分，2 小时为 59 分。现在试着找一条直线，根据学习时间 x 估计成绩。这些数据只是为了练习计算，不能据此判断真实同学的能力，也不能理解为不学习一定得 50 分。




图 1 真实样本与两条候选预测直线

$$\hat{y} = wx + b$$

x 是输入的学习时间； $\hat{y}$ 读作 “y hat”，表示预测成绩； w 是斜率，控制每多学习一小时预测增加多少分； b 是截距，表示 $x=0$ 时的预测。 w 和 b 是模型训练时要调整的**参数**。

学习时间 x	真实成绩 y	候选 A $\hat{y}=3x+50$	误差 $\hat{y}-y$	误差平方
0	50	50	0	0
1	52	53	1	1
2	59	56	-3	9

误差有正有负，直接相加会抵消。把误差平方后都变成非负数，也会更重视偏差特别大的预测。

3 用损失函数衡量整条线

为什么不能只看某一道题是否预测正确？一条直线要同时服务所有样本，某次误差很小也可能掩盖其他样本的大误差。损失函数把各样本误差合成一个数，才能比较两组参数。

$$L(w,b) = [(\hat{y}_1 - y_1)^2 + \dots + (\hat{y}_m - y_m)^2] \div (2m)$$

先用文字读公式：对每个样本，算“预测减答案”的平方；把这些平方加起来，再除以样本数的 2 倍。 Σ 是“把指定各项相加”的简写； i 是样本编号， i 从 1 到 m 表示从第一个一直加到第 m 个。

y_i 是第 i 个真实答案, $\hat{y}_i$ 是它的预测, 帽子形的小记号用来区别两者。 $L(w,b)$ 表示: 选定 w 和 b 后, 能算出一个损失数值。

m 是样本数, L 是整体损失。对上表的候选 A, $L=(0^2+1^2+(-3)^2)/(2\times 3)=5/3$ 。损失越小, 说明这组参数在这些样本上的预测越接近真实答案。公式中的 $1/2$ 只是为了后面求导更简洁。

选择学习 哪个直线更合适

图中的三个样本为 (0,50)、(1,52)、(2,59)。候选 A 是 $\hat{y}=3x+50$, 预测为 50、53、56, 平方误差为 0、1、9, 损失为 $10\div 6\approx 1.667$ 。候选 B 是 $\hat{y}=4x+50$, 预测为 50、54、58, 平方误差为 0、4、1, 损失为 $5\div 6\approx 0.833$ 。B 在这三条记录上的损失较小, 但不代表它最能预测所有学生的成绩。

4 多个特征时为什么需要点积

只有学习时间一个输入时, $w\times x$ 就够了; 房价却可能同时受面积、卧室数和房龄影响。为了让每个输入都贡献一次, 再把贡献加起来, 我们需要点积。

在 “ $3\times\text{面积}+10\times\text{卧室数}-2\times\text{房龄}+20$ ” 里, 每个特征前面相乘的数字叫权重; 最后单独相加的 20 叫偏置。权重控制某个输入改变时预测怎样变化, 偏置调节整体起点。它们都是参数。下面的房价数值与单位只供手算练习, 不用于真实估价。

真实问题通常有多个输入。若房价由面积、卧室数、房龄共同影响, 每个特征都有一个对应权重。把 “对应位置相乘后求和” 叫做点积。

$$\hat{y} = w^T x + b = 3\times 80 + 10\times 3 + (-2)\times 5 + 20 = 280$$

这里 $x=[80,3,5]^T$, $w=[3,10,-2]^T$ 。权重的正负表示在其他特征固定时, 这个特征增加会让预测倾向增加还是减少; 它不自动说明因果关系。

动手算 比较一次预测的误差

使用这一节损失 $L=(1/(2m))\sum(\hat{y}_i-y_i)^2$ 。对候选 A 的三个样本, 预测是 50、53、56, 误差 (预测减真实值) 是 0、1、-3, 所以 $L=(0^2+1^2+(-3)^2)/(2\times 3)=5/3\approx 1.67$ 。若把每个预测与答案比较后取平均平方误差、不乘 $1/2$, 结果则是 $10/3$; 两种记法只差一个固定倍数; 后面比较损失和调整参数时, 都要沿用同一套定义。

5 梯度下降 怎样让损失变小

先看只有一个参数的例子：模型直接输出 w ，正确答案是 3，损失规定为 $L = (w - 3)^2$ 。 $w = 1$ 时 $L = 4$ ；试着改为 1.1， $L = 3.61$ ；改为 0.9， $L = 4.41$ 。因此，在 $w = 1$ 附近，往增大的方向小走一步能减少损失。训练程序也需要一种办法判断这种方向。

用“损失变化量÷参数变化量”描述变化快慢。例如从 $w = 1$ 到 1.1，得到 $(3.61 - 4) \div (1.1 - 1) = -3.9$ 。步子缩成 0.01，得到 $(3.9601 - 4) \div 0.01 = -3.99$ 。步子越小，这个比值越靠近 -4；这个局部变化率叫导数，记作 dL/dw 。它不是 $L \div w$ ，而是“ w 改一点， L 大约跟着改多快”。负号表示在这里增大 w 会让 L 降低。

怎样不用反复试就算出 -4？把步长暂写成 h ，代入初中的平方展开： $(w + h - 3)^2 - (w - 3)^2 = 2(w - 3)h + h^2$ 。再除以 h ，得到 $2(w - 3) + h$ 。当 h 越来越接近 0，比值就越来越接近 $2(w - 3)$ 。所以这个损失的导数是 $2(w - 3)$ ，在 $w = 1$ 时为 -4。这是本例的推导，不是所有损失都用同一个导数公式。

一次向相反方向调整参数的做法叫梯度下降：新参数 = 旧参数 - 学习率 × 局部变化率。学习率是人设定的步长倍数。例如取 0.1，新 $w = 1 - 0.1 \times (-4) = 1.4$ ，新损失 = $(1.4 - 3)^2 = 2.56$ ，确实比 4 小。学习率若取 2，新 $w = 9$ ，损失反而变成 36。要边更新边检查，不能认为随便一步都会变好。

多个参数时，先固定其余参数，只考察其中一个参数的局部变化率，叫偏导数，写作 $\partial L / \partial w$ 或 $\partial L / \partial b$ 。把各参数的偏导数按固定顺序排成一组数，就叫梯度。下面的图只画一个参数；多个参数时，对各参数分别做同样的减法。

图中换用 $L(w) = 2(w - 2)^2$ ，只用于展示走向较低位置的过程；它的最低处在 $w = 2$ ，与上文最低处在 $w = 3$ 的例子不同。图里的 0.8 和 1.28 标的是参数位置，不是损失值。




图 2 另一个例子 $L(w) = 2(w - 2)^2$ 的下降方向

$$w_{\text{new}} = w - \eta \times (dL/dw)$$

η 是希腊字母，读作 eta；这里用它表示学习率，就是刚才取成 0.1 的步长倍数。下标 new 表示更新后的值。多个参数的变化率都应在同一组旧参数上算好，再一起更新，不能先改 w 后拿新 w 去算本次 b 的变化率。

$$\theta_{\text{new}} = \theta - \eta \times \nabla L(\theta)$$

θ 是“把所有参数放在一起”的简写，例如 $[w, b]^T$ ； ∇L 读作 L 的梯度。上式就是把刚才对单个数的减法改为逐项减法。训练重复“预测、算损失、算梯度、更新参数”。变化率为 0 时只说明当前用导数表示的局部变化率为 0，不保证已经找到所有可能取值里最小的损失。例如 $L = w^4 - w^2$ 在 $w = 0$ 处的变化率是 0，但 $w = 0.5$ 时损失反而更小。

6 选学 怎样从最后的误差倒着算变化率

为什么已经知道总损失，还要反向计算？损失只告诉我们“现在错了多少”，没有说明应调整哪一个参数、调整方向是什么。反向传播把最终误差沿计算步骤传回去，分别求出每个参数对损失的影响。

A2 到这里已经能完成一次参数更新。下面解释如何更快算出变化率。仍用直线模型 $\hat{y} = wx + b$ ，不需要先认识更复杂的模型。若 a 改一点会让 c 改 2 倍，而 c 改一点会让 L 改 3 倍，则这一条路径上 a 对 L 的局部影响是 $2 \times 3 = 6$ 。把相邻两步的局部变化率相乘，叫链式法则；有多条影响路径时，还要把各条贡献相加。

直线模型接收输入 x ，计算预测 $\hat{y} = wx + b$ ，再用 $L = \frac{1}{2}(\hat{y} - y)^2$ 衡量一个样本的误差。设 $x = 2$ 、真实值 $y = 1$ 、初始 $w = 0.2$ 、 $b = 0.1$ 。于是 $\hat{y} = 0.2 \times 2 + 0.1 = 0.5$ ，误差 $\hat{y} - y = -0.5$ ，损失 $L = \frac{1}{2} \times (-0.5)^2 = 0.125$ 。这里 $\frac{1}{2}$ 就是二分之一。

先解释本例的两个变化率。把预测值改为 $\hat{y} + h$ ，损失的变化量除以 h ，平方展开后是 $(\hat{y} - y) + h/2$ ；步子很小时就接近 $\hat{y} - y$ 。再看 $\hat{y} = wx + b$ ：固定 x 、 b ，把 w 加 h ，预测值就增加 hx ，所以预测对 w 的变化率是 x ；只把 b 加 h ，预测也加 h ，所以预测对 b 的变化率是 1。下面的式子只是把这几件事连起来。

从损失往回走：①损失对预测值的导数是 $\partial L / \partial \hat{y} = \hat{y} - y = -0.5$ 。②预测值对权重的导数是 $\partial \hat{y} / \partial w = x = 2$ ，所以链起来 $\partial L / \partial w = (\partial L / \partial \hat{y})(\partial \hat{y} / \partial w) = -0.5 \times 2 = -1$ 。③预测值对偏置的导数是 $\partial \hat{y} / \partial b = 1$ ，所以 $\partial L / \partial b = (\partial L / \partial \hat{y})(\partial \hat{y} / \partial b) = -0.5 \times 1 = -0.5$ 。

这就是反向传播的核心：从损失开始，沿计算过程倒着走，把每一步的局部导数相乘（链式法则），得到损失对各参数的梯度。这里梯度为负，表示稍微增大 w 、 b 会让这个例子的损失下降。若学习

率 $\eta=0.1$ ，则 $w_{\text{new}}=0.2-0.1\times(-1)=0.3$ ， $b_{\text{new}}=0.1-0.1\times(-0.5)=0.15$ 。更新后预测为 0.75，损失为 $\frac{1}{2}(0.75-1)^2=0.03125$ ，比 0.125 小。

对于有许多连续计算步骤的模型，可以先记录从输入到输出的计算，再从损失倒着走，利用链式法则计算各参数的变化率。这种高效求梯度的方法叫反向传播。它负责算出梯度；真正修改参数的仍是梯度下降等更新规则。A4 再把这个办法放进多层神经网络。

练习：沿用上例，若学习率改为 0.2，分别更新 w 和 b 。更新后预测是多少？损失是否下降？

参考答案： $w_{\text{new}}=0.2-0.2\times(-1)=0.4$ ； $b_{\text{new}}=0.1-0.2\times(-0.5)=0.2$ 。新预测为 $0.4\times 2+0.2=1$ ，损失为 0，低于原来的 0.125。这个简单例子刚好一步到达目标；一般问题不会如此整齐，学习率过大也可能越过较低损失区域。

可选挑战 亲手走一步

把三个样本的损失当作关于 w 、 b 的函数， $\hat{y}_i=wx_i+b$ 。此处损失定义为 $L=(1/(2m))\sum(\hat{y}_i-y_i)^2$ ，梯度为 $\partial L/\partial w=(1/m)\sum(\hat{y}_i-y_i)x_i$ 、 $\partial L/\partial b=(1/m)\sum(\hat{y}_i-y_i)$ 。从候选 A 的 $w=3$ 、 $b=50$ 出发，学习率 $\eta=0.1$ ，各更新一次，新的参数和损失是多少？

自己试一试

模型为 $\hat{y}=2x+1$ 。对样本 $(x,y)=(3,8)$ ：①算预测值；②算误差；③算平方误差。若 $dL/dw=-4$ 、学习率 $\eta=0.1$ ，算更新后的 w 。

参考答案：上面的练习中， $\hat{y}=7$ ，误差为 -1，平方误差为 1。最后一问把 $dL/dw=-4$ 作为单独给定的条件，并非从前面的样本推导而来；因此新 $w=2-0.1\times(-4)=2.4$ 。可选挑战中，三个误差为 0、1、-3，故 $\partial L/\partial w=(0\times 0+1\times 1-3\times 2)/3=-5/3$ ； $\partial L/\partial b=(0+1-3)/3=-2/3$ 。用旧参数同时更新后， $w\approx 3.167$ 、 $b\approx 50.067$ ，新预测约为 50.067、53.233、56.400，损失约为 1.381，小于原来的 1.667。

一页记忆

特征是输入属性，特征向量是按固定顺序打包的多个特征。参数是训练中调整的数字。损失衡量预测和答案的差异。梯度指向上升最快方向，梯度下降沿反方向更新参数。

进一步阅读

把每个误差平方后求平均，叫均方误差，简称 MSE。也有教材在它前面再乘 $1/2$ ，这一节使用后一种。做题时先确认定义。还有人把“真实值减预测值”叫残差，它与这一节“预测值减真实值”的符号相反，不能混用。

这一节中，向量用来按顺序装数字，转置改变行列摆法。输入数据来自样本，参数是训练会调整的数字；两者即使都写成向量，也不能混淆。A4 会进一步解释矩阵乘法。