

A3 模型训练流程与数据集

理解怎样练习 怎样检查新题

模型训练的目标是让它处理新例子，但实际训练也可能让它记住旧例子的细节。这一节解释如何发现这种情况。读完后，你应能说明为什么练习用的数据和最后检查用的数据要分开。

阅读前先准备

请先读 A1 和 A2 第 1 至 5 节。这一节会使用样本、预测、参数、损失和梯度。若忘了梯度，可以先记起 A2 的做法：比较参数稍微变化时损失怎样变化，再朝损失变小的方向尝试调整。

1 训练时发生了什么

先用当前参数从输入算出预测，这段从前往后的计算叫前向传播。再计算损失，也就是预测与目标差别有多大的数值。接着计算各参数的梯度；沿已完成的计算倒着求这些变化率的方法叫反向传播，A2 的选学部分给出了例子。最后按指定规则改参数，负责这一步的计算方法叫优化器；这一节使用的规则就是 A2 的梯度下降。

顺序	发生的事	你可以怎样理解
1	取一小批训练样本	拿出几道练习题
2	前向传播得到预测	先独立作答
3	损失函数计算误差	核对错了多少
4	反向传播得到梯度	找出该怎样改
5	优化器更新参数	调整解题方法
6	下一批样本，重复	继续练习

训练完成后，固定参数并只做预测，称为**推理**。推理阶段通常不再用答案修改模型。

2 三份数据各司其职

为什么要把数据分开？如果用同一道题一边练习一边宣布自己考试合格，就无法知道遇到新题会怎样。我们把“学习参数”“选择训练方案”“报告最终效果”交给不同的数据，减少把熟题成绩误当作真实能力的风险。

数据集	用来做什么	能否更新参数	类比
训练集	学习规律，计算梯度	能	平时练习
验证集	选择设置和停止时机	不能	模拟考试
测试集	最后一次评估泛化能力	不能	期末考试

验证集不直接改参数，却会影响我们选什么模型、学习率和训练轮数，因此它已经参与开发。测试集应尽量留到所有选择完成后。反复根据测试集改模型，就相当于反复偷看期末答案。

计算机用于临时放置正在处理的数据和计算结果的空间叫内存。一次处理太多图片可能放不下，所以常把数据分成若干小批再计算。

3 一小批 一次更新和一整轮

为什么要分批、还要数轮次？一次用多少样本、已经更新几次参数、整份数据看过几遍，是三个不同的问题。下面分别给它们起名字，再用具体张数计算。

训练集很大时，通常不会一次全部送入模型。一次使用的一小批样本叫 **batch**；每更新一次参数叫一个 **step**；训练集大致全部看过一遍叫一个 **epoch**。例如训练集有 700 张图片，batch size=70，则一个 epoch 约有 10 个 step；训练 5 个 epoch 约有 50 次更新。

每轮开始前通常会打乱训练样本，减少固定顺序带来的偏差。最后一批不一定装满，例如 1,050 个样本按 100 分批，最后一批可有 50 个样本。

4 怎样发现训练过头

为什么训练损失一直下降也不能一直练？模型可能逐渐记住训练样本的细节，却越来越不善于处理新样本。把训练表现和验证表现并排看，才有机会发现这一变化。

训练损失下降说明模型越来越会处理见过的训练题；真正关键是验证表现。如果训练损失继续下降，验证损失却开始上升，模型可能正在记住训练集细节，这叫过拟合。




图 1 第 4 轮后验证损失上升，宜保存第 4 轮模型

A2 里的权重是乘在输入前面的可调数字，偏置是最后单独相加的可调数字。它们随训练改变。与之不同，学习率和每次取多少样本等设置通常由人选择，用来规定训练怎样进行。不要把这两类数字混为一谈。

欠拟合指模型连训练数据中的主要关系也没学好，训练和验证表现都较差。发现验证表现连续几轮没有改善时停止训练，叫早停；还应保存或恢复验证表现最好那一轮的参数。学习率、每批样本数等控制训练安排的设置叫超参数；它们与训练直接调整的模型参数不同。

5 数据泄漏 一个容易忽略的错误

为什么切分数据还不够？即使文件被放在不同文件夹，重复图片或用全部数据计算的预处理数值仍会把“考试信息”带进训练。检查数据怎样产生、怎样转换，才能让最终评估可信。

数据泄漏是把本该留到独立检查的信息提前用进训练或方案选择。例如，把同一张猫图的原图放进训练集，裁剪版放进测试集，模型可能认出已见细节，导致测试结果虚高。

另一个例子是调整数字大小。有一项特征在训练集里为 10、20、30，我们可以按“(原数 - 10) ÷ (30 - 10)”把它们变成 0、0.5、1。这种按规则调整数值尺度的处理常叫缩放或归一化。数字 10 和 30 来自训练集；验证和测试时仍用这两个数。例如新值 40 会变成 1.5，这是允许的，不应为了强行落在 0 到 1 之间而重新用测试数据计算最大最小值。若训练值全相等，分母会是 0，需要另定处理规则，例如统一记为 0。

因此先分开三份数据，再只用训练数据确定这类转换所需的数字，最后把同一套规则应用到验证集和测试集。这里“拟合”指根据已有数据确定模型或转换规则中的数字，不是复制答案。删去不合

适记录、补缺失值、调整尺度等建模前的整理，统称数据预处理。只要这些步骤需要从数据中确定数值或选择规则，也要遵守同样的分工。

再检查几个常见误区

划分数据之前先随机打乱，也不总是正确。若要预测未来，可以按时间先后切分；来自同一个人、同一次实验或同一段影片的关联样本，也应整体放在同一份中，避免相似内容同时出现在训练集和测试集。数据很少时，留出一份验证集的结果可能波动很大，需说明样本数，不要把一次分数当成普遍定论。

把概念串起来 猫狗分类

有 1,000 张已标注图片：700 张训练、150 张验证、150 张测试。设置 batch size=70。模型每个 step 看 70 张训练图，预测猫或狗、计算损失并更新参数；10 个 step 约完成 1 个 epoch。每轮后查看验证集，选择表现最佳的模型；最后只用一次测试集报告最终结果。

自己试一试

训练集有 960 个样本，batch size=128，训练 3 个 epoch。请估算：每个 epoch 有多少个 step？一共更新约多少次？如果训练准确率 99%、验证准确率 70%，更像欠拟合还是过拟合？

参考答案：本题约定每小批更新一次，保留最后没装满的一批。 $960 = 128 \times 7 + 64$ ，所以每轮先有 7 批各 128 个，再有 1 批 64 个，共 8 次更新；3 轮共 24 次。训练准确率远高于验证准确率，可能过拟合，但也要检查两份数据是否有明显差别。

想一想 为什么“99%”不能说明一切

某个模型训练集准确率为 99%，验证集为 70%。请判断可能的问题。随后检查训练集有 100 张图，其中 90 张为猫；模型总是预测“猫”时，在训练集上也能得到多少准确率？这种模型有用吗？

参考答案：两份准确率差距大，可能过拟合，也可能是训练大多用清晰照片、验证却用了模糊照片，或标签有错误。始终预测猫能答对 90 张，准确率 = $90 \div 100 = 90\%$ ，但一张狗都认不出。总分必须和实际错了哪些题一起看。

一页记忆

训练集用于学习，验证集用于做选择，测试集用于最终评估。batch 是一次看的一小批样本，step 是一次更新，epoch 是训练集看完一遍。训练损失好不等于模型好，要看验证和测试表现。

进一步阅读

在所有方案选择完成后才读取测试集结果。若看过测试表现后又改模型，测试数据就参与了选择，不能再把它视为完全独立的最终评估。

归一化不是唯一一种公式。上面的“减最小值、除以最大最小值之差”只是一种做法；重点是转换所用数字只从训练集确定，验证和测试沿用同样规则。