

A5 从下一个词元理解大语言模型

读完你会知道

这一节解释聊天模型怎样把已有文字变成后续文字。读完后，你能说明文字为何逐步出现，用给定数字算出候选概率，并区分训练时改参数与使用时生成回答。

读前回顾

先读 A1 至 A4 主课，无须先读 B1。A1 已介绍：大语言模型简称 LLM；模型处理的文字小块叫词元，英文 token；本次可参考的材料叫上下文。A4 已解释神经网络怎样算分数，以及 Softmax 怎样把多个分数变成总和为 1 的概率。接下来统一用“词元”称呼这些小块。

这里回顾 A1：词元可以是一个字、几个字、单词的一部分或标点。模型可识别的文字小块及其编号组成词表；按照指定规则把文本拆成这些小块的程序叫分词器。仅知道词表还不够确定所有切分细节，实际结果取决于分词规则。例如这里用“我 / 喜欢 / 苹果”示意，不表示真实模型一定这样切。

1 模型的工作可以从一个问题开始

为什么从“下一个”开始？一整段回答太长，难以一次说明模型究竟预测了什么。先只问“前文之后最可能接什么”，就能把输入、候选结果和连续生成的过程逐步看清。

假设输入是“今天放学后我去图书馆借了一本”。模型接下来该写什么？可能是“书”“漫画”“词典”，也可能是别的词。它不会先把整篇答案写在某处，再一次性拿出来；它先给许多可能的下一个词元分配分数，再把分数变成概率。

下面的概率是人为编出的小例子，假设前三个候选各占一个词元；“其他”合并了所有未单列的候选，不是词表里另有一个名叫“其他”的特殊答案。

一种可能的结果如下：

候选 词元	概率
书	0.70
漫画	0.20
词典	0.08
其他	0.02

所有候选概率相加为 1。模型可能选“书”，把上下文变成“.....借了一本书”，再为新的下一个词元计算概率。于是句子是一步一步长出来的。

2 “预测下一个词元”不是简单的自动补全

自动补全通常让人想到“把当前一句话补完整”。LLM 的训练任务也常写成“根据前文预测下一个词元”，但它学到的不是只把句尾补完。海量例子会让模型接触到问答、解释、代码、故事等多种上下文。于是同一个预测任务，也能支持多种文字工作。

例如，“水在标准气压下约在”后面，接“100 摄氏度沸腾”很合适；“这段代码为什么报错？”后面，合适的后续则可能是解释或修正建议。前面的文字不同，接下来合理的文字分布也不同。模型要做的是根据上下文形成这种分布。

“概率最高”也不等于“事实必定正确”。模型给出的概率表示它根据训练得到的规律对文字续接有多倾向，并不自动证明这段话真实。流畅的回答仍需结合证据检查。

3 用小词表算一次概率

为什么要把分数变成概率？模型给不同候选的原始分数可能是负数，且没有固定总和，不能直接说“有多大机会选它”。Softmax 将同一组分数换成和为 1 的权重，方便比较候选。

假设一个极小词表只有四个词元：猫、狗、跑、。。当上下文是“院子里的”时，模型内部先为四种选择算出四个分数，暂记作 z ：

词元	猫	狗	跑	。
分数 z	2	1	0	-1

分数不是概率：它可以为负，也不必相加等于 1。为了比较候选结果，我们使用前面 A4 见过的 Softmax。对分数 z_i ，先计算 e 的 z_i 次方，再除以所有候选的指数值总和：

$$p_i = e^{z_i} / \sum_j e^{z_j}$$

这里的 e 是固定的数学常数，约等于 2.718。它的作用是把任何实数分数变成正数，再统一缩放，使结果总和为 1。对于上面的四个分数，Softmax 约得到：

词元	猫	狗	跑	。
概率 p	0.644	0.237	0.087	0.032

手算猫的概率：分母约是 $e^2 + e^1 + e^0 + e^{-1} = 7.389 + 2.718 + 1 + 0.368 = 11.475$ ；所以猫的概率约为 $7.389 / 11.475 = 0.644$ 。其余选择也用同一个分母，概率加起来约为 1。这里每一步都只是普通数字运算。

想一想：如果给每个分数都加上 3，候选排序或概率会改变吗？把 e^3 从 Softmax 的分子和分母同时提出，可以发现概率不变。Softmax 主要比较分数之间的差距。

4 训练：让正确的下一个 词元 更容易被选中

为什么训练时需要损失？只看模型选中了哪个 词元，会漏掉它给正确答案分配了多少概率。损失把这个差距变成可比较的数，反向传播才知道怎样调整参数。

为了知道何时停止，词表通常还会包含具有特殊用途的编号，例如结束标记。它不是必须显示给读者的文字；选到它时，系统可以结束这一段生成。下表的“空”表示暂不计入任何正文，实际系统通常还会提供表示开始或对话格式的标记。

训练文字已有前后顺序。把“窗外下着大雨”拆为一串 词元 后，可以反复造出这样的练习：

模型看到的前文	要预测的正确 词元
空	窗外
窗外	下着
窗外 下着	大雨
窗外 下着 大雨	结束标记

模型读到前文，算出许多候选 词元 的概率。我们看正确答案分到的概率：如果正确答案“大雨”的概率是 0.8，它表现得不错；如果只有 0.1，它对这道练习就表现得较差。

这里的“正确答案”指训练文本里实际出现的下一个词元，不表示其他续写都不合语法，也不表示训练文本一定真实。损失只是衡量模型给这次指定目标分配了多少概率。

一种常用的单题损失是正确答案概率的负对数：

$$L = -\ln(p \text{ 正确})$$

$\ln$ 读作“自然对数”，可以把它理解为乘方的反向问题： e 的多少次方等于 p ？例如 $e^0 = 1$ ，所以 $\ln(1) = 0$ ； $e^{-1} \approx 0.368$ ，所以 $\ln(0.368) \approx -1$ 。若 $0 < p < 1$ ，答案是负数，前面再加负号就得到正的损失。 p 越接近 0，所需的负指数绝对值越大，损失也越大。跟着例子计算时可直接使用给出的数值，不要求手算小数对数： $p = 0.8$ 时损失约 0.223， $p = 0.2$ 时约 1.609。

一段文字里会有很多这样的预测。训练时先把每题损失求平均，再按 A3、A4 的流程反向求梯度、更新参数，反复处理大量文字。它和先前学到的“预测 → 损失 → 梯度 → 更新”是同一训练循环，只是预测目标换成了下一个 词元。

5 生成：训练完以后一步一步往前走

训练给出了模型参数；使用时，用户提供一段前文，模型重复以下过程：

1. 根据已有词元计算下一个词元的分数与概率。
2. 按某种选取规则挑出一个词元。
3. 把新词元接到上下文后面。
4. 重新计算，直到碰到结束标记或达到长度限制。

例如模型先选出“书”，新上下文里就包含了“书”；接下来它可以选“，”，再选“我”，继续形成文字。模型所说的“记住上下文”，就是新词元会成为后续预测可见的输入之一。

选最高概率的词元是一种简单策略，但实际系统也可能依照概率抽取，以获得多样写法；具体策略会影响生成结果。这不改变主线：每一步预测的是一个词元，较长回答来自许多步的连续预测。

可以用纸条模拟按概率选取：假设“书”占70%、“漫画”占20%、“词典”占10%，就在100张纸条上分别写70、20、10张，混合后抽一张。它说明小概率候选也可能被选到，并不是电脑真的准备纸条。若始终选最大项，这一步总选“书”；若按概率抽取，同样的输入可能得到不同结果。

训练和生成要分开：训练时已有目标答案，用它计算损失、调整参数；生成回答时通常没有现成答案供逐步核对，参数固定，变化的是已经写出的上下文。因此“它看起来越来越懂这一段对话”不等于本次聊天一直在训练参数。

6 LLM 的“本质”该怎样准确表达

初学时可以记成：“LLM 是一个训练过的神经网络；给它前文，它为下一个词元给出一组分数或概率，文字由连续预测生成。”这句话说明了它正在执行什么计算。

模型每一步选取一个词元，不代表内部只做了很简单的统计，也不代表只会照抄原句。A4 的多层计算让模型能组合许多信息，但能力究竟怎样要靠实际检查。下一课会解释如何让不同位置提供线索，A7 再把这些计算组装成一种常用的模型结构；现在不用先记它的英文名字。

也要区分模型和产品。模型负责根据输入计算后续文字；聊天应用负责接收问题、组织材料、显示结果，并可能连接搜索等工具。应用交给模型、用来约束回答方式的文字叫系统指令。应用提供了什么材料、实际调用了什么工具，都会影响最终回答。

自己试一试

1. 模型对正确词元给出概率 0.5 或 0.9，哪个概率对应较小的 $-\ln(p)$ ？为什么？
2. 计算 $\text{Softmax}([0,0])$ 。提示：两项完全相同。

3. 看到前文“雨停以后，太阳从云层后面”，生成模型每一步做什么？为什么新词元会改变后续预测？

4. 有人说：“模型最常给出的词元就是已经证明为真的事实。”指出这句话把哪两件事混在了一起。

参考答案

1. 0.9；正确答案概率越大，负对数越小。 $-\ln(0.5) \approx 0.693$ ， $-\ln(0.9) \approx 0.105$ 。

2. [0.5,0.5]：相等的两项各占总和一半。

3. 先算下一个词元的分数或概率，选一个词元后接到上下文里，再为新的上下文算下一步。新词元改变了已知前文，因此后续预测条件也变了。

4. 把“模型偏好怎样续写文字的概率”误当成“关于现实真假的证据”。两者不是同一概念。

一页记忆

LLM 把文字切成词元。给定已有词元，模型计算下一个词元的分数，Softmax 可将分数变成概率。训练会降低正确词元的负对数损失；生成时则一次选出一个词元，再用新的上下文继续预测。回答通不通顺不等于事实一定正确。

延伸阅读

Radford 等，*Language Models are Unsupervised Multitask Learners* (GPT-2 报告)，OpenAI:

[https://cdn.openai.com/better-language-](https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf)

[models/language_models_are_unsupervised_multitask_learners.pdf](https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf)。这里的小数字例子只用于解释“根据前文预测后文”；它不是报告里的训练数据。