

A6 自注意力如何让文字互相提供线索

读完你会知道

先读 A5。这一节用一个人指定为小数字例子，说明一句话中各个位置怎样从别处取得信息。读完后，你能从头算出一个位置的新向量，并说明每一步为什么需要。

读前回顾

向量是有固定次序的一列数，点积把对应位置相乘再相加。矩阵可以把多个向量计算一次写完。Softmax 把分数转换成总和为 1 的概率。下面把这些熟悉的运算用于一句话里的词元。

1 为什么需要在句子里“查看前文”

先比较：“猫追着球跑，因为它想抓住球。”这里“它”指猫；“猫追着球跑，因为它滚到了沙发下。”这里“它”指球。要判断指谁，需要把句中有关词语联系起来，不能只认出“它”这个字。这一节先演示整句已给出时怎样汇总线索；如果任务是继续生成文字，就只能参考已经出现的部分，A7 会解释如何限制不能看的位置。

这种让一句话里的每个位置都能按需查看其他位置，并汇总线索的方法，叫**自注意力 (self-attention)**。

“自”表示查询线索和供查询的线索都来自同一段输入；“注意力”在这里是计算规则，不表示模型像人一样有意识。

可以把它想成查图书卡片：

当前读者写下一个**查询** (query, Q)：“我现在想找什么线索？”

每张卡片写着一个**键** (key, K)：“我能提供什么线索？”

卡片里面实际记录的内容是**值** (value, V)：“如果你要看这张卡，带走这份信息。”

查询和键用来算匹配分数；值才是真正被加权汇总的内容。Q、K、V 都是给已有概念起的名字，实际是向量。

2 输入数字从哪里来

为什么要先给词元一个数字表示？点积和矩阵只能处理数字，不能直接对“小猫”两个字做乘法。嵌入向量把词元变成能参与计算的一列数；这一节先用人为设定的小数字练习。

模型先把每个词元变成一列数字，也就是嵌入向量。本例为了能手算，直接规定三枚词元的向量：

位置	词元	输入向量 x
1	小猫	$[1,0]^T$

位置	词元	输入向量 x
2	吃	$[0,1]^T$
3	鱼	$[1,0]^T$

真实模型的向量由训练得到，通常有很多维；这里用二维只是为了手算。相同向量也不表示现实中“小猫”和“鱼”是同一个东西；本例特意把嵌入简化了。

模型用三组可学习的矩阵 WQ 、 WK 、 WV ，分别把输入变成查询、键和值：

$$q_i = WQx_i, \quad k_i = WKx_i, \quad v_i = WVx_i$$

令 $WQ = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ 、 $WK = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$ 、 $WV = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ 。这三个矩阵在练习计算时暂时视为已知数字；训练中它们会像 $A4$ 的权重一样被更新。算出：

位置	q (查询)	k (键)	v (值)
1	$[1,0]^T$	$[2,0]^T$	$[1,0]^T$
2	$[0,1]^T$	$[0,2]^T$	$[0,1]^T$
3	$[1,0]^T$	$[2,0]^T$	$[1,0]^T$

注意： $\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ 乘任何两项列向量都会保留原值，叫单位矩阵； $\begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$ 则把每项乘 2。这些是人为选来方便手算的权重，不是模型天生就有的语言知识。

3 查询如何挑选可用线索

为什么查询要与所有键比较？当前词元可能需要前面、后面或自己提供的信息；只看一个固定位置会漏掉线索。逐个算匹配分数后，再把它们变成权重，才能决定从每个位置取多少值。

位置 2（“吃”）的查询为 $q_2 = [0,1]^T$ 。它依次与三个键做点积。我们先不管缩放，看到的分数是：

$$q_2^T k_1 = 0, \quad q_2^T k_2 = 2, \quad q_2^T k_3 = 0$$

键 2 与当前查询的点积最大；换句话说，这组数字认为位置 2 最应该参考自己所在的位置。这个分数不是概率，只是一个匹配分数。Softmax 把 $[0,2,0]$ 变成权重 $[0.107, 0.787, 0.107]$ （约数）。三个权重加起来为 1。

右上角的 T 表示转置，即把列改为行；下方的数字才是位置编号。例如 q_2 是第 2 个位置的查询， k_1 是第 1 个位置的键。 $q_2^T k_1$ 就是把两组数对应相乘再相加，结果只有一个数。

4 为什么要除以根号维度

若查询和键各有很多个分量，点积会把很多次乘法结果加起来，分数容易变大。Softmax 碰到很悬殊的分数时，可能几乎把全部权重给最大项，其余项接近 0，模型就不容易平稳调整权重。

分量是向量里的一个数，维度是这些数的个数。 d_k 表示每个查询或键含几个数，下面的 k 只是名称的一部分。平方根 $\sqrt{2} \approx 1.414$ ，表示平方后等于 2 的正数。这里除以 $\sqrt{2}$ ，就是把每个分数除以约 1.414。

因此先把点积除以查询的维度 d_k 的平方根，再进行 Softmax。这个版本叫**缩放点积注意力**；“缩放点积”说的就是“点积以后除以一个数”：

$$s_{ij} = \mathbf{q}_i^T \mathbf{k}_j / \sqrt{d_k}, \quad a_{ij} = e^{s_{ij}} / \sum_j e^{s_{ij}}$$

本例向量有两维，所以 $d_k=2$ 。位置 2 的未缩放分数 $[0,2,0]$ 变成 $[0,\sqrt{2},0]$ ，再经过 Softmax 得到：

$$a_2 \approx [0.1636, 0.6728, 0.1636]$$

检查一下：最大分数对应最大权重；三项加起来约为 1。前一页不缩放时最大权重约 0.787；缩放后约 0.673。除以 $\sqrt{2}$ 把权重分配得没那么极端。

5 怎样从线索得到新的表示

加权求和就是先给各组数乘上各自的份额，再对应相加。例如两份成绩 60、80，各占 25% 和 75%，结果是 $0.25 \times 60 + 0.75 \times 80 = 75$ 。对向量也一样，只是每个位置分别算： $0.25 \times [1,0]^T + 0.75 \times [0,1]^T = [0.25, 0.75]^T$ 。这些份额在这里叫注意力权重，与训练中不断调整的矩阵参数要区分：注意力权重会随着这次输入而重新计算。

注意力权重现在告诉我们每个位置该从哪里取多少值。位置 2 的输出，是把三个 v 按权重相加：

$$z_2 = 0.1636v_1 + 0.6728v_2 + 0.1636v_3$$

$$z_2 = 0.1636[1,0]^T + 0.6728[0,1]^T + 0.1636[1,0]^T = [0.3272, 0.6728]^T$$

此处的 z_2 表示经过自注意力后、位置 2 的新表示；不要把它误当成前课神经元中的激活前值。可以看到，大约 67% 的值来自“吃”自己，约 33% 来自另两个位置。这个新向量再交给模型后面的计算。

完整的单位位置计算顺序：输入 $x \rightarrow$ 算查询 q 、键 k 、值 $v \rightarrow$ 查询和每个键点积 $\rightarrow$ 除以 $\sqrt{d_k} \rightarrow$ Softmax 得注意力权重 $\rightarrow$ 用权重加权求和所有值，得到新表示。每个箭头都是前课见过的矩阵、点积、指数或加法。

6 把所有位置一起写成矩阵

为什么把单个位置的算式改写成矩阵？若一句话有很多词元，逐个位置计算会重复相同的步骤。把所有输入按列排列，可以一次得到每个位置对所有位置的分数，同时更容易核对维度。

把每个词元的列向量按顺序排成矩阵 X 。三列分别对应“小猫、吃、鱼”：

$$X = [[1, 0, 1], [0, 1, 0]], \quad Q = WQX, \quad K = WKX, \quad V = WVX$$

我们的约定是“每一列对应一个词元”。因此 Q 、 K 、 V 每一列仍对应一个位置。让所有位置彼此打分，得到：

$$S = Q^TK / \sqrt{d_k}, \quad A = \text{按行 Softmax}(S), \quad Z = VA^T$$

这里的 Softmax 按 S 的每一行分别计算，使“某一个查询对所有键”的权重加起来等于 1。行 i 、列 j 是第 i 个位置给第 j 个位置的权重。公式的矩阵方向来自这一节“每列是一个词元”的约定。很多书把词元放在矩阵的行，于是写成 $\text{Softmax}(QK^T/\sqrt{d_k})V$ ；意思相同，只是转置方向换了。

维度检查

本例输入有 $d=2$ 个特征、 $n=3$ 个词元，所以 $X: 2 \times 3$ 。 Q 和 K 是 2×3 ， Q^TK 是 3×3 ，每一行对应一次查询的三个分数； A 是 3×3 ； VA^T 是 $(2 \times 3)(3 \times 3) = 2 \times 3$ ，输出仍是每个词元一列。

7 用全句分数表核对一次

我们的三个查询与三个键产生：

$$S = [[\sqrt{2}, 0, \sqrt{2}], [0, \sqrt{2}, 0], [\sqrt{2}, 0, \sqrt{2}]]$$

按行 Softmax，约得：

查询位置	看“小猫”	看“吃”	看“鱼”
1 “小猫”	0.4458	0.1084	0.4458
2 “吃”	0.1636	0.6728	0.1636
3 “鱼”	0.4458	0.1084	0.4458

每一行都是一次独立 Softmax，所以每行合计约为 1。第二行正是上一页手算的结果。把所有权重放在一张表上，只是同时计算三个查询；没有更神秘的运算。

本例特意使用人为指定的二维表示。它示范公式如何得到数字，**不在展示训练好的语言理解，也不代表模型会把“吃”与什么词对应**。若模型想学到有用的语言规律，输入向量和 WQ 、 WK 、 WV 都须经过数据训练。

8 自注意力有什么用，又有什么限制

一旦每个位置能读取其他位置的值，它就能按当前的查询组合线索。短语指代、长距离的主谓关系、前文提到的人名，都可以成为可学习的模式。位置与位置之间不必挨在一起，仍可直接计算匹配。

这不表示权重表是可靠的人类阅读说明。数值可以帮助我们追踪这个公式做了什么，但权重本身并不能证明模型为何作出某项判断。其他层的计算、表示方式也会影响最终结果。

自己试一试

1. 查询 $q=[1,0]^T$ ，三个键是 $[2,0]^T$ 、 $[0,2]^T$ 、 $[2,0]^T$ 。不缩放时三个点积是多少？
2. 这一节的 $d_k=2$ 。若某个点积是 4，缩放后的分数是多少？
3. 给值 $[1,0]^T$ 和 $[0,1]^T$ 的权重各为 0.25 和 0.75。加权结果是什么？
4. 自注意力先用 Q/K 做什么，再用 V 做什么？为什么“点积分数就是答案”说得不对？
5. 当输入矩阵按“每列一个词元”排列时， X 有 5 个词元、每个词元 4 个特征，其形状是什么？

参考答案

1. $[2,0,2]$ 。直接配对计算： $1 \times 2 + 0 \times 0 = 2$ ； $1 \times 0 + 0 \times 2 = 0$ ；第三项与第一项相同。
2. $4/\sqrt{2} = 2\sqrt{2} \approx 2.828$ 。
3. $0.25[1,0]^T + 0.75[0,1]^T = [0.25, 0.75]^T$ 。
4. Q 与每个 K 算匹配分数，Softmax 把分数变成权重；再按权重汇总 V 。分数只决定取哪些值、各取多少，本身不含最终输出向量。
5. 4×5 ：每个词元占一列。

一页记忆

Q 提出当前查询， K 用来比较匹配， V 提供实际要汇总的信息。点积 $\rightarrow$ 除以 $\sqrt{d_k} \rightarrow$ Softmax $\rightarrow$ 按权重加权 V ，得到每个位置的新表示。注意力权重之和为 1，矩阵方向要结合“每一列一个词元”的约定理解。

延伸阅读

Vaswani 等，*Attention Is All You Need*，第 3.2 节：<<https://arxiv.org/abs/1706.03762>>。原文常把词元按行排成矩阵；这里沿用 A5 的列向量写法，因此将矩阵公式按同一约定转置。